University of Palestine

Faculty of Software Engineering and Artificial Intelligence

التحديات والمخاطر الرقمية

(BSAI 3131)

Lecture 5: AI as a Source of Challenges and Risks

الذكاء الاصطناعي كمصدر تحديات ومخاطر

Dr. Eng. Alaa AbuZaiter

First Semester 2025-2026

أهداف المحاضرة

آليات الإساءةExplain

شرح كيفية استخدام AI لأغراض ضارة: هجمات سيبرانية مؤتمتة، تلاعب بالمحتوى، محاكاة شخصيات

الوسائط الاصطناعيةAnalyze

تحليل أخطار Deepfakes على الهوية، الأمن السياسي، والاحتيال المالي

التحيز والعدالة Evaluate

تقييم التحيز في أنظمة التوظيف، التعرف على الوجوه، والقرارات القضائية

مخاطر الخصوصيةAssess

تقييم هجمات Model Inversion، Membership Inference، وتسريب البيانات

حلول تقنيةPropose

اقتراح Differential Privacy، Federated Learning، و Fairness Constraints

إساءة استخدام الذكاء الاصطناعي

التعريف التقني

استخدام أنظمة الذكاء الاصطناعي **خارج الغرض المصمم** أو بطريقة ضارة (Malicious or Unintended Use)

أشكال الإساءة

- **Automation of Cyber Attacks**
  توليدPhishing بـ NLP • Malware ذكي
- **Content Manipulation**
  أخبار مزيفة تلاعب بالرأي العام
- **AI-powered Social Engineering**
  Voice Cloning • محاكاة شخصيات

دراسات حالة واقعية

ChatGPT للاحتيال
استخدام نماذج توليد نصوص لإنشاء رسائل احتيال عالية الإقناع تخطي الفلاتر الأمنية

Business Email Compromise
هجمات متطورة تستخدم AI لمحاكاة أسلوب المدير التنفيذي في المراسلات

تحليل هندسي: المشكلة في

- Lack of Access Control
- Weak Usage Policies
- Absence of Monitoring

الوسائط المزيفة والاصطناعية

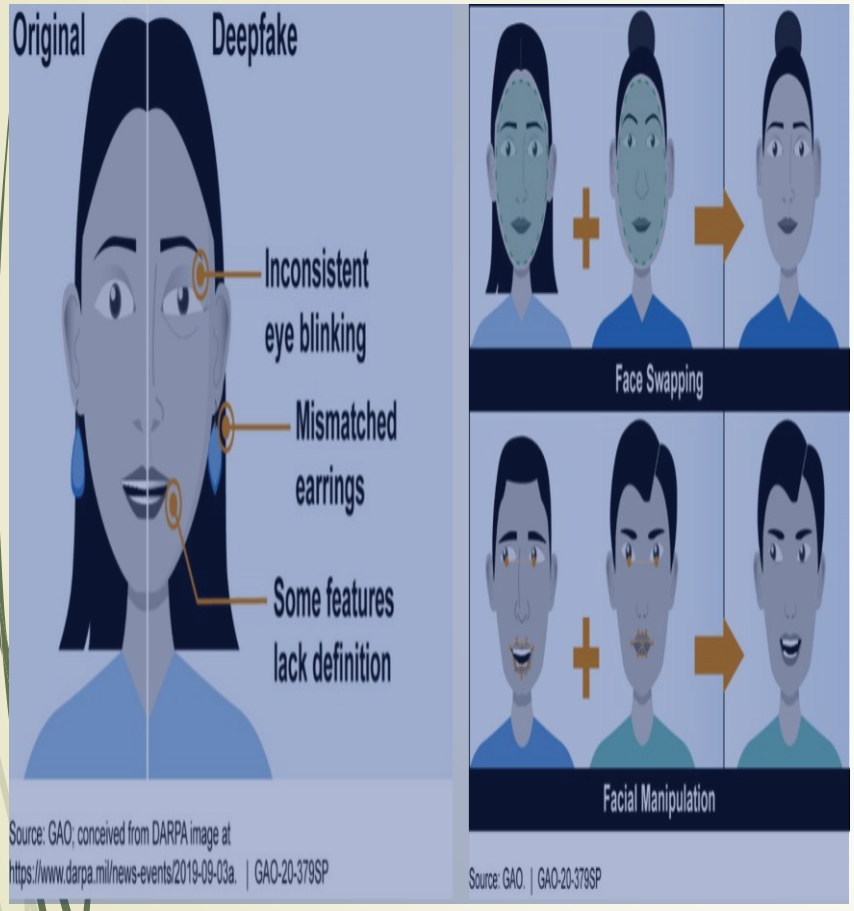

محتوى يُولّد باستخدام **GANs** (شبكات الخصومة التوليدية) و **Diffusion Models**

- ✓ Deepfake Video - تبديل الوجوه
- ✓ Synthetic Voice - استنساخ الأصوات
- ✓ AI-generated Images - صور مزيفة
- ✓ Identity Theft - سرقة الهوية
- ✓ Political Manipulation - التلاعب السياسي
- ✓ Fraud & Blackmail - الاحتيال والابتزاز

تقنيات الكشف والمواجهة

Deepfake Detection Algorithms: خوارزميات تحليل الانماط

Blockchain Verification: التحقق عبر البلوكتشين

Digital Watermarking: العلامات المائية الرقمية

التحيز والعدالة في الذكاء الاصطناعي

التعريف التقني

Bias = انحراف في المخرجات

انحراف منهجي في نتائج النموذج بسبب **بيانات غير متوازنة** أو **تصميم منحاز** يؤدي إلى تمييز غير عادل

مصادر التحيز

ثلاثة مصادر رئيسية

- **Algorithmic Bias:** تحيز الخوارزمية نفسها
- **Dataset Bias:** تحيز في البيانات المدربة
- **Human Bias:** التحيز البشري في التسمية

أمثلة واقعية ملموسة

حالات تطبيقية

- **Gender Bias:** أنظمة توظيف ترفض النساء
- **Racial Bias:** دقة أقل في التعرف على الأعراق
- **COMPAS:** تحيز في النظام القضائي

الحلول التقنية

استراتيجيات المعالجة

- **Data Balancing:** موازنة البيانات
- **Fairness Constraints:** قيود العدالة
- **XAI:** الذكاء الاصطناعي القابل للتفسير

مخاطر الخصوصية في نماذج الذكاء الاصطناعي

التعريف التقني

احتمالية **تسريب أو استنتاج بيانات حساسة** من النموذج المدرب على معلومات شخصية

أنواع هجمات الخصوصية

- **Model Inversion Attack**
  إعادة بناء بيانات المستخدم من سلوك النموذج
- **Membership Inference Attack**
  معرفة ما إذا كانت بيانات ضمن التدريب
- **Data Leakage**
  تسريب مباشر في مخرجات النموذج

دراسات حالة خطيرة

تسريب بيانات طبية

مدرب على سجلات مرضى كشف AIنموذج معلومات حساسة عن حالات نادرة

مكشوفةChatbots

محادثات كشفت معلومات شخصية بشكل غير مباشر من بيانات التدريب

الربط مع دور الطالب

كمستخدم (User)

التحقق من المحتوى

Deepfake Awareness - فحص صحة المحتوى الرقمي والتمييز بين الحقيقي والمزيف

حماية البيانات الشخصية

الحفاظ على خصوصية المعلومات الحساسة وعدم مشاركتها مع أنظمة AI غير موثوقة

عدم الثقة العمياء في AI

التحقق والتمييز بين المصادر الموثوقة وغير الموثوقة والتشكيك في النتائج

كمطور (Developer)

Design for Security & Ethics

تصميم آمن وأخلاقي من البداية مع مراعاة مبادئ الخصوصية والأمان

Privacy-preserving Techniques

تطبيق تقنيات حماية الخصوصية مثل التشفير و Differential Privacy

Test for Bias and Fairness

اختبار التحيز والعدالة قبل النشر وتحسين النموذج باستمرار

خلاصة هندسية

- **زيادة مساحة الهجوم**

الذكاء الاصطناعي يزيد **Attack Surface** للنظام - كل تقنية AI جديدة تضيف نقاط ضعف محتملة يجب حمايتها وتأمينها

- **مخاطر اجتماعية-تقنية**

المخاطر ليست تقنية فقط بل **Socio-Technical Risks** - تتعلق بالتفاعل بين التقنية والمجتمع والإنسان

- **تقييم شامل للنماذج**

كل نموذج AI يجب تقييمه من حيث: **Security** (الأمن)، **Privacy** (الخصوصية)، **Fairness** (العدالة)، **Ethical Impact** (التأثير الأخلاقي)

- **نهج متكامل**

الحلول تتطلب **نهجاً متكاملاً** يجمع بين التقنية والسياسات والتنظيم والمسؤولية الاجتماعية

الوسائط الاصطناعية المزيفة

فيديوهات سياسية مزيفة

- ✓ تقلبات حادة عند نشر فيديوهات مزيفة لقادة سياسيين
- ✓ تهديد الاستقرار السياسي والأم الوطني
- ✓ استخدام Deepfakes للتلاعب بالناخبين والتأثير على النتائج

احتيال استنساخ الصوت

- ✓ مكالمة بصوت مدير الشركة يطلب تحويل أموال عاجل
- ✓ ملايين الدولارات محولة بناءً على محادثات مزيفة
- ✓ AI يستخدم عينات صوتية قصيرة لاستنساخ الصوت بدقة

استراتيجيات التخفيف من المخاطر

مكافحة إساءة استخدام AI

- **Access Control Systems**
  تحديد هوية المستخدمين وحقوق الوصول
- **Usage Policies & Monitoring**
  سياسات الاستخدام وتتبع السلوك
- **Real-time Threat Detection**
  كشف التهديدات الفورية

كشف الوسائط المزيفة

- **AI Detection Algorithms**
  خوارزميات تحليل الانماط المزيفة
- **Blockchain Verification**
  التحقق وتوثيق المحتوى الأصلي
- **Digital Watermarking**
  العلامات المائية لتتبع المصدر

معالجة التحيز والعدالة

- **Data Balancing**
  موازنة البيانات لتمثيل عادل
- **Fairness Constraints**
  تطبيق معايير العدالة في التدريب
- **Explainable AI (XAI)**

حماية الخصوصية

- **Differential Privacy**
  إضافة ضوضاء لحماية البيانات
- **Federated Learning**
  تدريب محلي بدون مشاركة البيانات
- **Secure Model Deployment**